



# Análisis de Series de Tiempo

Carrera de Especialización en Inteligencia Artificial

---

**Clase 1**





Ing. Magdalena Bouza, Ing. Carlos German Carreño Romano

# Cronograma

---




Clase 1	Introducción, nociones básicas de modelado
Clase 2	Modelos estacionarios
Clase 3	Aplicaciones, presentación de TP
Clase 4	Tendencia y estacionalidad
Clase 5	Predicciones
Clase 6	Aplicaciones. Análisis espectral
Clase 7	Heterocedasticidad. Markov.
Clase 8	Evaluación final

# Bibliografía



# ¿Qué es una serie de tiempo?

Un registro de un fenómeno que varía en el tiempo de forma irregular es una serie de tiempo.



# ¿Para qué estudiar Series de Tiempo?

---

En general no podemos asumir que la **observación** surge independientemente de una población común. Estudiar modelos que incorporen **dependencia** es la clave en TSA.

- **Descripción:** se desea resumir las características de una serie de tiempo.
- **Modelado:** se busca identificar un modelo aproximado del problema. Es necesario identificar un modelo correcto, así como los parámetros asociados al mismo.
- **Predicción:** el objetivo es conocer, o predecir, el comportamiento futuro del sistema.
- **Extracción de señales:** de todo el modelo, se busca extraer ciertas señales que resultan de interés para el problema en cuestión

# Clasificación de Series de Tiempo

---

- **Continuas o discretas:** En general se consideran series de tiempo discretas, ya que los datos suelen medirse en intervalos de tiempo
- Univariadas o **multivariadas:**
- **Estacionarias o no estacionarias:** cuando la serie de tiempo estudiada proviene de realizaciones de un proceso estocástico con una estructura invariante en el tiempo se lo llama estacionario.
- **Gaussianas** o no gaussianas: Si la serie de tiempo sigue una distribución Gaussiana o no,
- **Lineales** o no lineales: se dice que una serie de tiempos es lineal si puede modelarse como la salida de un sistema lineal
- Observaciones faltantes y outliers:

# Series de tiempo y Procesos estocásticos

# Procesos estocásticos

Las series de tiempo forman parte de lo que se conoce como procesos estocásticos.

Así como las variables aleatorias mapean los posibles resultados de un experimento aleatorio a un número (real), los procesos estocásticos mapean los resultados de un experimento aleatorio a un conjunto de funciones en el tiempo.

- recordar media, var, cov, autocorrelacion, PSD
- definir estacionariedad




Figure 3.2 Example of a random process.



# Algunos momentos

---

Una serie de tiempo  $Y(t)$ , puede entonces modelarse a través de la secuencia de variables  $\{Y(t), t = t_k, t_{k+1}, \dots, t_{k+n}\}$  que definen un proceso estocástico. Gran parte de la información de la distribución de estos procesos está contenida en los momentos de dicha distribución: medias, varianzas y covarianzas. A diferencia de las variables aleatorias, estos momentos deberán definirse como función del tiempo.

- **Media** (o esperanza):  $\mu_t = \mathbb{E}[Y_t]$
- **Función de autocovarianza:**  $C_{t,s} = Cov(Y_t, Y_s) = \mathbb{E}[(Y_t - \mu_t)(Y_s - \mu_s)]$
- **Función de autocorrelación:**  $R_{t,s} = Corr(Y_t, Y_s) = \frac{Cov(Y_t, Y_s)}{\sqrt{var(Y_t)var(Y_s)}}$

# Algunos momentos (caso multivariado)

---

Análogamente, si se tiene una serie de tiempo multivariada, donde  $Y_t = [Y_t^{(1)}, \dots, Y_t^{(l)}]$ , definimos

- **Media** (o esperanza):  $\mu_t = [\mu_t^{(1)}, \dots, \mu_t^{(l)}] = [\mathbb{E}[Y_t^{(1)}], \dots, \mathbb{E}[Y_t^{(l)}]]$

- **Matriz de cross-covarianza:**  $C_{t,s} = \begin{bmatrix} C_{t,s}^{(1,1)} & \dots & C_{t,s}^{(1,l)} \\ \vdots & \ddots & \vdots \\ C_{t,s}^{(l,1)} & \dots & C_{t,s}^{(l,l)} \end{bmatrix}$ , donde  
$$C_{t,s}^{(i,j)} = \text{Cov}(Y_t^{(i)}, Y_s^{(j)}) = \mathbb{E}[(Y_t^{(i)} - \mu_t^{(i)})(Y_s^{(j)} - \mu_s^{(j)})]$$

- **Matriz de cross-correlación:**  $R_{t,s} = \begin{bmatrix} R_{t,s}^{(1,1)} & \dots & R_{t,s}^{(1,l)} \\ \vdots & \ddots & \vdots \\ R_{t,s}^{(l,1)} & \dots & R_{t,s}^{(l,l)} \end{bmatrix}$

# Estacionariedad

---

Una suposición que suele hacerse a la hora de modelar series de tiempo es la estacionariedad.

Se dice que un proceso es **estacionario** (*stationary*) si la distribución del proceso no cambia a lo largo del tiempo. Matemáticamente, quiere decir que

$$f_{Y_{t_1}, \dots, Y_{t_n}} = f_{Y_{t_1+\delta}, \dots, Y_{t_n+\delta}}, \quad \forall t_1, \dots, t_n, \forall \delta$$

Una conclusión que se desprende de esta definición es que si los procesos son estacionarios, su media es constante en el tiempo y las funciones de autocorrelación y autocovarianza dependen sólo de la diferencia de tiempos:

$$\mu_t = \mu_s = \mu \quad \forall t, s$$

$$C_{t,s} = Cov(Y_t, Y_s) = Cov(Y_{t+\delta}, Y_{s+\delta}) = C_{s-t}, \quad \forall s, t, \delta$$

$$R_{t,s} = Corr(Y_t, Y_s) = Corr(Y_{t+\delta}, Y_{s+\delta}) = R_{s-t}, \quad \forall s, t, \delta$$

# Estacionariedad débil

---

En muchos casos, si bien no se cumple el supuesto de estacionariedad, vale lo que se conoce como estacionariedad débil.

Se dice que un proceso es **débilmente estacionario (DE)** si sólo se cumple

$$\mu_t = \mu_s = \mu \quad \forall t, s$$

$$C_{t,s} = Cov(Y_t, Y_s) = Cov(Y_{t+\delta}, Y_{s+\delta}) = C_{s-t}, \quad \forall s, t, \delta$$

$$R_{t,s} = Corr(Y_t, Y_s) = Corr(Y_{t+\delta}, Y_{s+\delta}) = R_{s-t}, \quad \forall s, t, \delta$$

Es decir que sólo se pide que sean estacionarios los momentos hasta de segundo orden.

En general cuando hablemos de series de tiempo estacionarias nos estaremos refiriendo a este tipo de estacionariedad.

# Estimación de momentos

---

Dadas  $N$  muestras de una serie de tiempo DE  $\{y_1, \dots, y_N\}$ , entonces podemos estimar los momentos como:

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N y_i$$

$$\hat{C}_k = \frac{1}{N} \sum_{n=k+1}^N (y_n - \hat{\mu})(y_{n-k} - \hat{\mu})$$

$$\hat{R}_k = \frac{\hat{C}_k}{\hat{C}_0}$$

# Preprocesamiento

# ¿ Cuándo aplicar un preprocesamiento?

---

Cuando la distribución de la serie de tiempo cambia a lo largo del tiempo se dice que es **no estacionaria**.

En estos casos, pueden aplicarse transformaciones para que la serie de tiempo resultante sea aproximadamente estacionaria.

Algunos métodos:

1. Transformación de variables
2. Diferenciación
3. Promedio móvil

# 1. Transformación de variables

---

Muchas series de tiempo tienen la característica de que sus varianzas van aumentando a medida que avanza el tiempo.





Se pueden aplicar transformaciones a los puntos de la serie de tiempo.

- Transformación Box-Cox

$$y_i^{(\lambda)} = \begin{cases} \frac{y_i^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0, \\ \ln y_i & \text{si } \lambda = 0 \end{cases}$$



# 1. Ejemplos



## 2. Diferenciación

---

Si la serie presenta una tendencia podemos analizar en su lugar la serie diferenciada. Dada una serie de tiempo  $y_n$ ,  $n = 0, 1, \dots$  definimos

$$z_n = \Delta y_n = y_n - y_{n-1}$$

**Motivación:** si  $y_n = an + b$ , al diferenciar obtendríamos una constante.

**Observación:** En general, si  $y_n$  se corresponde con un polinomio de grado  $n$ , diferenciando  $n$  veces recuperamos una constante.

# Ejemplos

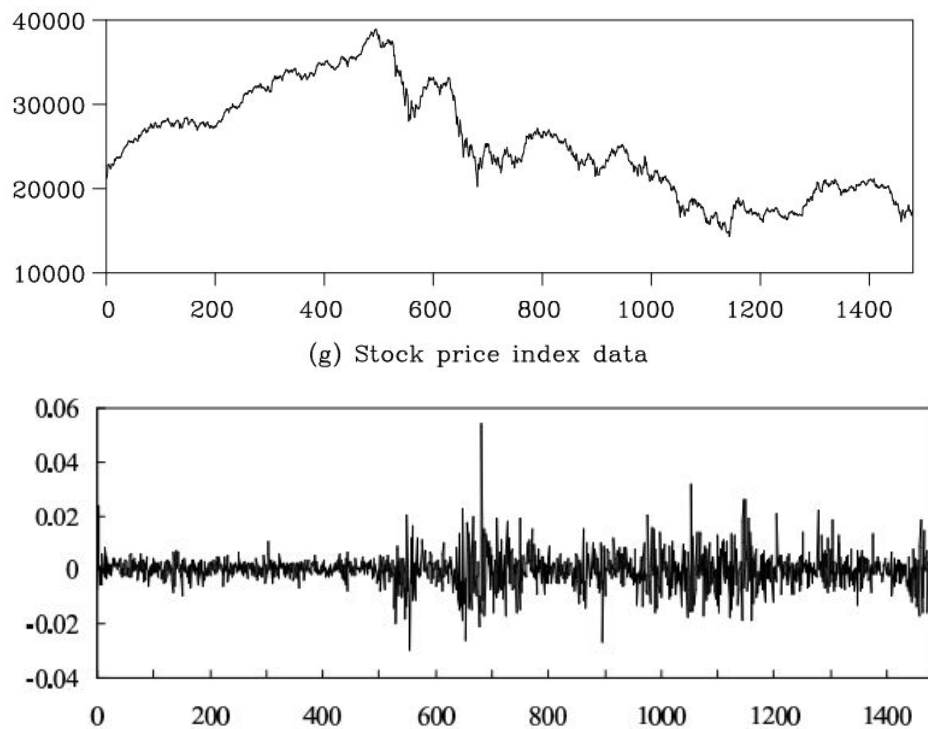


Figure 1.2: *Difference of the logarithm of the Nikkei 225 data.*

### 3. Promedio móvil

Para una serie de tiempo  $y_n$ , el promedio móvil de  $(2k + 1)$  términos está dado por

$$T_n = \frac{1}{2k+1} \sum_{j=-k}^k y_{n+j}$$

Si modificamos la definición intercambiando la media por la mediana obtenemos la mediana móvil, definida como

$$T_n = \text{mediana}\{y_{-k}, \dots, y_k\}$$

En general, la mediana móvil puede capturar cambios en la tendencia más rápido que el promedio móvil.




Figure 1.4 *Maximum temperature data and its moving average. Top left: original data, top right: moving average with  $k = 5$ , bottom left:  $k = 17$ , bottom right:  $k = 29$ .*